

Escopo Pretendido e Justificativa da Pesquisa

O objetivo inicial da coleta de dados era documentar o discurso institucional e público em torno da COVID-19 no Brasil, com atenção particular a como agências oficiais de saúde pública (por exemplo, OMS, ANVISA, CDC e ECDC) usaram o Twitter para disseminar informações e moldar narrativas públicas, e como os cidadãos responderam linguisticamente a essas mensagens institucionais.

Para atingir esse fim, o pesquisador desenhou uma estratégia ampla de recuperação de dados usando a API do Twitter, empregando consultas baseadas em palavras-chave e hashtags em vez de rastreamento de contas específicas. Essa abordagem assegurou a inclusão não apenas de declarações oficiais e conteúdos de agências de notícias, mas também da ampla ecologia discursiva que cerca essas mensagens: comentários, sátiras, citação, reação e reconfiguração ideológica.

Embora a recuperação tenha sido desenhada para focar na comunicação em saúde pública, a amplitude dos termos de busca (por exemplo, saúde, covid, vacina, pandemia, Anvisa, Covid-19, OMS, CDC e ECDC) capturou uma mistura heterogênea de registros e posturas discursivas. O corpus resultante, portanto, representa um discurso público em rede, e não um registro estritamente institucional.

Emergiram três grandes agrupamentos de conteúdo:

1. Comunicação Institucional e Mediação Midiática

- Tweets de contas de ministérios, agências de saúde e grandes veículos de imprensa.
- Anúncios de campanhas de vacinação, atualizações de dados epidemiológicos e mensagens de utilidade pública.
- Conteúdo oficial retweetado com mínimo comentário do usuário.
- Emolduramento metadiscursivo por jornalistas ou figuras políticas, frequentemente citando a linguagem da agência, mas incorporando marcadores de avaliação (por exemplo, ironia, alinhamento ou crítica).

2. Reação Pública e Comentário

- Tweets expressando concordância ou discordância com diretrizes de saúde ou políticas de vacinação.
- Avaliações leigas de risco, eficácia e competência governamental.
- Discurso moral e afetivo (por exemplo, apelos à solidariedade, frustração com restrições, cansaço, raiva contra atores políticos).

- Uso frequente de emojis e marcadores pragmáticos (por exemplo, risada, descrédito, exasperação) que indexam postura e intensidade emocional.

3. Usos Recontextualizados ou Ideológicos

- Reformulações meméticas de slogans oficiais.
- Reinterpretações politizadas de dados epidemiológicos (por exemplo, enquadrando números de casos como evidência favorável ou desfavorável à política governamental).
- Tweets usando vocabulário pandêmico metaforicamente ou sarcasticamente (por exemplo, “covid do governo”, “variante da corrupção”).
- Retweets irônicos de manchetes de notícias ou declarações públicas, frequentemente com emojis afetivos ou texto avaliativo mínimo.

Assim, embora o alvo do pesquisador fosse o discurso institucional da comunicação em saúde pública, o corpus tal como coletado reflete um espaço dialógico dinâmico: um contínuo que vai de registros institucionais formais a contradiscurso vernáculo respondendo ou parodiando essas vozes institucionais.

Limpeza dos Dados do Twitter e Preparação do Corpus

O corpus do Twitter analisado neste estudo foi derivado de dados brutos coletados por meio da API do Twitter. O conjunto inicial de dados consistia de arquivos JSONL (JavaScript Object Notation Lines), cada um contendo múltiplos objetos de tweet, um por linha. Embora o formato JSONL seja eficiente para recuperação e armazenamento de dados, ele apresenta desafios significativos para análise linguística em larga escala devido à sua estrutura aninhada, campos de metadados heterogêneos e formatação inconsistente entre lotes de coleta. Para enfrentar esses desafios, os dados foram reformulados por meio de um pipeline estruturado em várias etapas, projetado para transformar os despejos brutos de JSONL em um corpus padronizado e relacional, adequado para análise linguística quantitativa e qualitativa. A prioridade foi dada à manutenção da integridade do texto de um tweet, fosse ele um retweet ou não, e à preservação dos vínculos com mídia visual no tweet.

A primeira etapa desse processo envolveu dividir os arquivos JSONL em arquivos de tweet discretos. Cada linha no arquivo JSONL original foi analisada como um objeto JSON individual e gravada em seu próprio arquivo, gerando assim um conjunto consistente “um-tweet-por-arquivo”. Essa conversão garantiu que cada tweet pudesse ser acessado e modificado independentemente, sem a sobrecarga computacional de ler arquivos de origem com vários gigabytes — o que poderia ser dispendioso em termos de tempo no desktop e em termos de custo na nuvem. O procedimento de

divisão também minimizou erros de análise que ocorrem frequentemente quando objetos JSON malformados estão embutidos em grandes conjuntos de dados delimitados por linha. Como parte dessa mesma etapa, os arquivos resultantes foram organizados em diretórios que espelhavam seus lotes de coleta originais, facilitando a rastreabilidade subsequente e o acompanhamento de proveniência.

Na segunda etapa, os arquivos JSON individuais foram padronizados ou “embelezados”, usando um script Python personalizado que aplicou indentação consistente, ordenação de chaves e normalização Unicode. Esse processo assegurou que todos os arquivos compartilhassem uma estrutura idêntica, o que melhorou muito a transparência dos dados e permitiu a aplicação confiável de expressões regulares e ferramentas de análise automatizadas. Embora essa etapa possa parecer apenas cosmética, ela foi crucial para manter a reprodutibilidade do processo de preparação do corpus, pois pequenas inconsistências na formatação JSON podem levar a resultados de análise diferentes em sistemas variados e versões das bibliotecas JSON do Python.

```
"referenced_tweets": [
  {
    "type": "retweeted",
    "id": "1633156604337225728"
  }
],
"possibly_sensitive": false,
"lang": "pt",
"created_at": "2023-03-07T19:20:31.000Z",
"edit_controls": {
  "edits_remaining": 5,
  "is_edit_eligible": false,
  "editable_until": "2023-03-07T19:50:31.000Z"
},
"reply_settings": "everyone",
"id": "1633185880595738624",
"text": "RT @revistaeste: Anvisa suspende autorização de medicamento da AstraZen",
"context_annotations": [
  {
    "domain": {
      "id": "123",
      "name": "Ongoing News Story",
      "description": "Ongoing News Stories like 'Brexit'"
    },
    "entity": {
      "id": "1220701888179359745",
      "name": "COVID-19"
    }
  }
],
```

A terceira etapa focou na extração de informações linguísticas e contextuais relevantes de cada tweet. Um conjunto de scripts Python analisou o texto do tweet e os metadados, recuperando identificadores de autor, timestamps, informações de conversação e resposta, e estatísticas de engajamento quando disponíveis. Atenção especial foi dada ao tratamento de entidades como hashtags, menções de usuário, URLs e links de mídia. O processamento de emojis apoiou-se na biblioteca open-source Emojificate (pypi.org/project/emojificate/). A Emojificate operacionaliza o conceito de representação de emoji em HTML através de imagens de fallback, alt text, título e rótulos ARIA — uma abordagem mais acessível do que depender dos padrões do navegador. Essa representação orientada à acessibilidade apoia a comparabilidade de

corpora entre plataformas e dispositivos e alinha-se com padrões atuais de design web inclusivo e curadoria de dados em humanidades digitais. Sua inclusão nesse fluxo de trabalho garantiu que caracteres emoji fossem convertidos em espaços reservados textuais (por exemplo, `{{face_with_tears_of_joy}}`), preservando assim suas funções semânticas e pragmáticas para análise linguística.

Os dados estruturados resultantes foram gravados em lotes de valores separados por vírgula (CSV) para armazenamento eficiente e carregamento incremental. Esses lotes foram, em seguida, importados para um banco de dados relacional SQLite, onde uma série de scripts SQL organizou as informações em tabelas normalizadas e visões analíticas. O esquema do banco de dados foi projetado para ligar tweets aos seus autores, anexos de mídia e identificadores de conversação. Além disso, campos derivados foram criados para facilitar operações subsequentes no corpus, tais como concordância baseada em tokens, análises de colocação e modelagem baseada em fator.

Nas etapas finais do pipeline, as tabelas curadas foram exportadas como arquivos de valores separados por tabulação (TSV) para integração em ambientes de software estatístico e linguístico (por exemplo, R, Python ou Sketch Engine).

Como grandes conjuntos de dados do Twitter frequentemente incluem conteúdo repetido — particularmente por meio de retweets, mensagens citadas ou cadeias de texto replicadas — o corpus foi sistematicamente desduplicado para assegurar a integridade das contagens de frequência lexical. Instâncias de conteúdo textual idêntico foram identificadas e colapsadas, sendo retida apenas a ocorrência mais antiga para preservar a coerência cronológica. Esse procedimento minimizou redundância e evitou a inflação artificial de frequências de tokens nas etapas posteriores de análise de corpus.

Criação do Corpus

O corpus resultante representa uma amostra em larga escala do discurso em língua portuguesa nas redes sociais, consistindo de 127.355 tweets únicos produzidos por uma ampla gama de usuários e totalizando 24.724.649 tokens e 15.805 imagens anexadas. As seções seguintes descrevem os métodos empregados para padronizar, anotar e refinar o conjunto de dados, incluindo os procedimentos iterativos de desduplicação e o enriquecimento linguístico provido pelo analisador de dependências da spaCy. (spaCy é uma ferramenta de Processamento de Linguagem Natural (PLN) que identifica as relações gramaticais (dependências sintáticas) entre as palavras em uma frase. Ele constrói uma árvore de dependência que mostra qual palavra é o "cabeça" (head) de outra palavra e qual é o tipo de relação entre elas).

Estrutura dos Dados

Cada tweet foi representado como uma única linha no conjunto de dados, com colunas discretas correspondendo tanto a variáveis de nível textual quanto de nível de metadados. Os principais campos textuais estão resumidos na Tabela 1, seguidos pelos metadados associados na Tabela 2.

Tabela 1. Campos Textuais no Corpus de Tweets

Campo	Descrição
text	Conteúdo original do tweet conforme recuperado pela API do Twitter.
text_emojified	Representação normalizada na qual emojis foram substituídos por tokens textuais descritivos usando a biblioteca Emojificate.
text_emojified_truncated	Variante truncada usada para detecção eficiente de duplicados.
text_uniq	Identificador hash único (ID) correspondente a cada string de texto, usado para vincular duplicados entre lotes.

Tabela 2. Campos de Metadados

Campo	Descrição
conversation_id	Identificador que vincula tweets dentro do mesmo fio de conversação.
retweet	Valor booleano que distingue tweets originais de retweets.
media_key, media_origin, photo_url, photo_uniq_id	Metadados que descrevem arquivos de mídia anexados e seus identificadores únicos.
author_id, username	Identificadores numéricos e textuais do usuário autor do tweet.
created_at, created_at_secs	Tempo de criação do tweet, armazenado em formato legível ao ser humano e em formato Unix-epoch para ordenação cronológica.
lang	Código de idioma atribuído pela API do Twitter.

Campo	Descrição
tweet_url	URL canônica do tweet para rastreabilidade.

Desduplicação Iterativa e o Desafio da Variação de Emoji

A deduplicação (o processo de identificar e remover registros idênticos ou quase idênticos de um conjunto de dados para garantir que cada instância linguística seja representada apenas uma vez) representou uma das etapas mais tecnicamente exigentes na construção do corpus. A plataforma Twitter produz ampla redundância textual, pois os usuários frequentemente retweetam conteúdo idêntico ou copiam mensagens inteiras manualmente, muitas vezes alterando apenas emojis ou pontuação. Essas diferenças mínimas — embora comunicativamente significativas — geram complicações importantes para a modelagem de corpus. A primeira etapa da desduplicação (o processo de identificar e remover registros idênticos ou quase idênticos para garantir que cada texto seja representado apenas uma vez) ocorreu durante a combinação inicial dos arquivos brutos, onde tweets repetidos dentro de cada lote foram identificados e removidos com base na cronologia (isto é, prevalece o primeiro tweet). A segunda etapa (descrita aqui) então abordou duplicatas em todo o conjunto de dados.

Uma interação distinta abordou a variação de emoji. Emojis podem aparecer duplicados ou codificados de forma diferente entre plataformas, complicando a correspondência textual. Como emojis transmitem nuance afetiva, sua eliminação correria o risco de perda semântica. Em vez disso, eles foram normalizados via a biblioteca Emojificate, substituídos por tokens textuais tais como {{Emoji:_Face_with_Tears_of_Joy}}.

Os exemplos a seguir ilustram a gama de fenômenos de duplicação encontrados após a conversão de emoji, mostrando como tweets podem diferir apenas minimamente em ortografia, codificação ou pontuação, porém transmitir conteúdo comunicativo idêntico.

Tweet 1

Varíola dos macacos no Brasil é “muito preocupante”, alerta OMS. Especialistas temem repetição de erros da covid.

Tweet 2

Varíola dos macacos no Brasil é “muito preocupante”, diz OMS. Especialistas temem repetição de erros da covid.

A diferença chave entre os dois tweets é o verbo usado para atribuir fala à agência OMS (Organização Mundial de Saúde): o Tweet 1 emprega “alerta”, enquanto o Tweet

2 usa “diz”. Ambos os verbos reportam a mesma afirmação informacional — que a OMS considera a varíola dos macacos no Brasil “muito preocupante” — contudo a distinção muda sutilmente a postura do discurso. Consequentemente, esses foram tratados como dois tweets separados.

Tweet 3

Uti's pediátricas lotando, casos de CªVID aumentando e as crianças entre 3 e 5 anos, seguem sem PROTEÇÃO! Libera @anvisa_oficial Temos URGÊNCIA! segue o fio {{Emoji:_White_Down_Pointing_Backhand_Index}} com o APELO dos maiores interessados {{Emoji:_Heart}}

Tweet 4

Uti's pediátricas lotando, casos de COVID aumentando e as crianças entre 3 e 5 anos, seguem sem PROTEÇÃO! Libera @anvisa_oficial Temos URGÊNCIA! segue o fio {{Emoji:_White_Down_Pointing_Backhand_Index}} com o APELO dos maiores interessados {{Emoji:_Heart}}

Os Tweets 3 e 4 apresentam outro caso de quase-duplicação, mas, neste caso, a diferença é puramente ortográfica em vez de lexical. No Tweet 3, a palavra COVID aparece como CªVID, refletindo um erro de substituição de caractere introduzido durante a conversão UTF-8. Fora esse artefato de codificação, as duas mensagens são idênticas em todos os demais aspectos, incluindo pontuação, posição dos emojis e menções de usuário. Como essa discrepância não corresponde a nenhuma distinção semântica ou linguística, os dois foram tratados como um único tweet no processo de deduplicação. Esse exemplo ilustra como pequenas inconsistências de codificação de caracteres podem surgir quando dados de redes sociais são colhidos de múltiplas fontes ou processados através de diferentes locais de sistema, e como tais artefatos precisam ser normalizados para preservar a integridade linguística do corpus.

Tweet 5

Sem a OMS não há pandemia- Sem a OTAN não há guerra- Sem o Banco Central Europeu não há inflação- Sem o Foro Econômico Mundial não há Great Reset.
<https://t.co/KsTISciBTo>

Tweet 6

Sem a OMS não há pandemia; sem a OTAN não há guerra; sem o Banco Central Europeu não há inflação ; sem o Foro Econômico Mundial não há Great Reset.

Embora esses dois tweets difiram em pontuação, são semanticamente e lexicalmente idênticos. A variação reside apenas no uso de travessões (–) versus pontos-e-vírgulas (;) para separar as orações e em diferenças mínimas de espaçamento. Essas alterações não alteram o conteúdo proposicional, as relações sintáticas ou a função

discursiva da mensagem. Ambos expressam a mesma estrutura paralela contrastando presença institucional e crises globais.

Como a diferença é puramente ortográfica — e porque URLs nesse corpus não foram consideradas parte do texto significativo — esses tweets foram tratados como instâncias equivalentes durante a deduplicação. Essa decisão alinha-se às práticas padrão de limpeza de corpus, que distinguem variação linguisticamente significativa (lexical, morfológica ou sintática) de variação de formatação que surge de estilo de usuário ou convenções de dispositivo.

Tais casos ressaltam a importância de definir o que conta como um tipo de texto único em corpora em redes sociais em larga escala. Variação de pontuação pode refletir estilo pessoal, mas quando não carrega consequência semântica ou pragmática, colapsar essas duplicatas preserva a clareza analítica sem obscurecer a diversidade linguística.

Análise de Dependência e Enriquecimento Linguístico com o spaCy

Após a deduplicação, a anotação linguística foi feita usando a biblioteca de dependências do spaCy (Explosion AI, 2023).

Parsing de dependência — que engloba processos como rotulagem de parte-do-discurso — é o processo de analisar a estrutura gramatical de uma frase identificando as relações “cabeça-dependente” entre palavras. Em vez de representar a sintaxe por meio de estruturas hierárquicas de frase, um parser de dependência codifica relações gramaticais como links direcionados entre tokens individuais, onde cada palavra (exceto a raiz) depende de outra que serve como seu governador sintático. Esse modelo é particularmente útil para análises baseadas em corpus e computacionais porque permite aos pesquisadores rastrear funções gramaticais (por exemplo, sujeito, objeto, modificador) diretamente até os itens lexicais que as realizam.

O parser de dependência do spaCy atribui a cada token uma etiqueta de parte-do-discurso, um lema e um rótulo de dependência que especifica seu papel gramatical. Conceitualmente, isso produz uma representação interpretável da sintaxe que pode ser armazenada como texto estruturado ou como uma rede de relações.

Por exemplo, na frase em português:

O ministro anunciou novas medidas sanitárias.

Uma representação textual simplificada da saída parseada é mostrada abaixo:

Token	Lemma	POS	Dependência	Cabeça
O	o	DET	det	ministro

Token	Lemma	POS	Dependência	Cabeça
ministro	ministro	NOUN	nsubj	anunciou
anunciou	anunciar	VERB	ROOT	—
novas	novo	ADJ	amod	medidas
medidas	medida	NOUN	obj	anunciou
sanitárias	sanitário	ADJ	amod	medidas
.	.	PUNCT	punct	anunciou

Essa representação indica que ‘anunciou’ (announced) é a raiz da oração, governando dois dependentes principais: o sujeito (‘ministro’) e o objeto (‘medidas’). Cada dependente pode por si só ter modificadores (‘O’ e ‘novas sanitárias’, respectivamente). Tal estrutura fornece uma descrição linguisticamente transparente de como o significado e as relações gramaticais são codificados, facilitando análises posteriores de padronização sintática, expressão de postura e variação de registro dentro do corpus.

O spaCy é uma ferramenta de processamento de linguagem natural (NLP) baseada em Python, amplamente utilizada em linguística de corpus e computacional para tokenização, rotulagem de parte-do-discurso, lematização e parsing de dependência sintática. Seus modelos são treinados em grandes corpora anotados e aderem ao framework Universal Dependencies (Nivre et al., 2016), tornando-o particularmente adequado para gerar anotações linguisticamente interpretáveis que podem ser comparadas entre idiomas e registros.

O modelo grande para português (pt_core_news_lg) foi empregado para realizar tokenização, rotulagem de parte-do-discurso e análise morfológica. Hashtags foram mantidas como itens lexicais, porém o símbolo “#” foi removido. Cada token foi anotado com lema, POS, características morfológicas e relação de dependência. O parsing de dependência atribuiu relações cabeça-dependente entre tokens, possibilitando a extração de estruturas predicado-argumento e padronização gramatical. Grafos de dependência foram armazenados em JSON, assegurando portabilidade sem sobrecarregar o banco de dados. A precisão do parser foi avaliada manualmente em amostras aleatórias; embora ligeiramente menor para o português informal online, os resultados foram suficientes para o perfil global do corpus.

Preparação do Corpus para Análise Lexical Multidimensional

O corpus foi preparado de acordo com os procedimentos da Lexical Multidimensional Analysis (LMD), conforme descrito por Thiago B. Sardinha (2000, 2004). A LMD paralela a estrutura multidimensional de Biber, concentra-se em conteúdo lexical em vez de categorias gramaticais, identificando padrões de associação entre os lemas mais frequentes em um corpus. O objetivo do processo de preparação foi transformar o conjunto de dados anotado em uma matriz de frequência lexical padronizada, adequada para análise de fator – uma matriz capaz de revelar as estruturas de coocorrência que caracterizam variação de registro e discurso.

Consolidação Lexical e Extração de Lemas

A preparação começou com a consolidação de todas as formas lematizadas produzidas pela fase de parsing de dependência. A lematização garantiu que variantes morfológicas (por exemplo, fala, falar, falou) fossem tratadas como instâncias do mesmo tipo lexical (falar), preservando generalidade semântica e reduzindo redundância. A partir do inventário lexical completo, foram calculadas contagens de frequência para cada lema em todo o corpus. Em conformidade com a metodologia de Sardinha, apenas os 1 000 lemas mais frequentes foram retidos para análise multidimensional. Esse limiar equilibra representatividade lexical com estabilidade estatística: preserva os itens que contribuem de forma mais consistente para o significado textual, excluindo palavras de baixa frequência cuja ocorrência esporádica pode distorcer correlações. O conjunto resultante de 1 000 lemas formou o espaço lexical variável central para as análises subsequentes. (anexo no trabalho)

Indexação de Variáveis e Construção da Matriz

A próxima etapa organizou essas frequências de lemas normalizadas em uma matriz texto-por-variável, onde cada linha correspondia a um texto individual e cada coluna a um dos 1 000 lemas. Essa estrutura representa a “impressão lexical” de cada texto em espaço de alta dimensão. A matriz captura como os itens lexicais mais frequentes coocorrem no corpus, codificando a informação estatística necessária para identificar agrupamentos de itens lexicalmente associados.

Padronização e Modelagem de Correlação

Para preparar a matriz para análise de fator, os valores de frequência foram padronizados (pontuações-z). Isso colocou todas as variáveis lexicais na mesma escala estatística, evitando que lemas altamente frequentes dominassem a estrutura de correlação. Em seguida, foi calculada uma matriz de correlação entre todas as variáveis lexicais, quantificando quão fortemente cada par de lemas co-variava entre os textos do conjunto. Correlações positivas indicam itens lexicais que tendem a aparecer juntos nos mesmos contextos comunicativos, enquanto correlações negativas destacam palavras que caracterizam registros ou funções discursivas contrastantes.

Pré-Fatoração e Resultado Analítico

Uma matriz de correlação constituiu a estrutura final de dados usada para a análise de fator propriamente dita. A extração de fatores identifica agrupamentos de lemas co-ocorrentes — dimensões lexicais estatisticamente independentes — que refletem padrões subjacentes de variação no discurso. Cada dimensão corresponde a um campo lexical coerente ou a uma orientação comunicativa, como linguagem informacional versus interpessoal, ou registo institucional versus avaliativo. Por meio dessa série de transformações — extração de lemas, filtragem de frequência, normalização, padronização e modelagem de correlação — o corpus foi reduzido a uma representação linguisticamente interpretável e estatisticamente tratável. O foco nos 1 000 lemas mais frequentes assegurou que a análise multidimensional fosse alicerçada nas tendências lexicais centrais do corpus, em vez de em vocabulário periférico ou idiossincrático. Isso produziu uma base equilibrada e reproduzível para a identificação das dimensões lexicais que estruturam o discurso relacionado à pandemia nas mídias sociais brasileiras.

[nota: é aqui que entreguei os dados para vocês. Não fiz a análise de fator no SAS.]

Morgan, J. (2022). Emojificate: Accessible emoji conversion for HTML text [Computer software]. PyPI. <https://pypi.org/project/emojificate/>

Explosion AI. (2023). spaCy: Industrial-strength natural language processing in Python [Computer software]. Explosion. <https://spacy.io>

Nivre, J., de Marneffe, M.-C., Ginter, F., Goldberg, Y., Hajic, J., Manning, C. D., McDonald, R., Petrov, S., Pyysalo, S., Silveira, N., Tsarfaty, R. & Zeman, D. (2016). Universal Dependencies v1: A multilingual treebank collection. In Proceedings of the 10th International Conference on Language Resources and Evaluation (LREC 2016) (pp. 1659–1666). European Language Resources Association (ELRA). <http://universaldependencies.org>

Sardinha, T. B. (2000). Dimensions of variation across corpora: Applying multidimensional analysis to Brazilian Portuguese [Doctoral dissertation, Lancaster University]. Lancaster University Repository.

Sardinha, T. B. (2004). Linguística de corpus [Corpus linguistics]. São Paulo: Manole.

